



**Universidad
Andrés Bello**

Universidad Andrés Bello
Magíster Ciencias de la Computación
Reconocimiento de Patrones

Proyecto

Reconocimiento de Patrones

Alumno

Luis Suazo Suazo

Profesor

Juan Tapia

Noviembre, 2017

Tabla de Contenidos.

1.- Introducción.	2
2.- Trabajos Relevantes.	2
3.- Tabla de comparación.	8

1.- Introducción.

En este trabajo se hará un resumen de los trabajos relevantes sobre la detección patrones en uvas. En la investigación se detectaron 2 grandes problemas, la detección de la uva blanca en entornos naturales (Behroozi-Khazaei et. al., 2017) y la clasificación de uvas según su grado de madurez (Rahman et. al., 2014). Para la clasificación de la madurez de uvas, se han encontrado dos propuestas, la primera es identificar la madurez fenólica de las semillas de uvas, la madurez fenólica óptima para la cosecha es cuando los taninos de las semillas son mínimos y los fenoles de la piel máximos, resultando en un vino menos amargo y con un rico aroma (Zuñiga et. al., 2014), y la otra es separar la uva blanca del entorno y después clasificarla. El segundo problema radica en la segmentación de la uva blanca del entorno. A continuación se revisará los artículos por orden de año de publicación y finalmente se hará una tabla resumen con los elementos claves de cada investigación.

2.- Trabajos Relevantes.

En el 2014, Avila et. al. presenta un método para estimar la madurez fenólica de la Uva basado en imágenes de semillas. En el trabajo de Avila et. al., separaron las semillas por 2 clases, maduras e inmaduras, un experto enólogo les ayudó a etiquetar estas semillas, en la Figura 1 se observa las semillas a clasificar. El método propuesto por ellos consta de tres etapas: segmentación, extracción de características y clasificación. La segmentación trata de separar una semilla de su sombra, se realizó mediante un método híbrido que combinaba el aprendizaje supervisado y no supervisado, este paso sirve para identificar que las características propias de una semilla de uva.

Para el aprendizaje supervisado utilizaron el algoritmo de selector de características SFS (Selección secuencial adelantada), para obtener el mejor canal de la imagen de la semilla, probaron con modelos de colores, RGB, HSV, YIQ, incluyendo los modelos de invariantes I1I2I3 y c1c2c3. El selector de características dio como resultado en el canal c3, están las mejores características, las cuales arrojó 9 características relevantes. Estas características sirven como entrada a una red neuronal que clasifica si una imagen es o no es semilla. En el aprendizaje no supervisado utilizaron los modelos invariantes c1c2c3, donde utilizaron el canal c3, debido a que fue elegido por el selector de características. La segmentación automática del canal c3 se realiza por método Otsu.

Entonces, el método propuesto se basa en fusionar las características de las imágenes obtenidas por ambos aprendizajes, para mejorar los resultados, utilizaron una secuencia de operaciones morfológicas binarias para eliminar el ruido presente en la imagen. Para llevar a cabo esta parte del experimento, utilizaron 1000 imágenes (500 semillas y 500 sombras), de 41x41, separadas en dos clases, semilla y no semilla los resultados de esta parte del experimento fue de un performance del 0.8, en la Figura 3 se observa el resultado final de fusionar ambos métodos.

Para la extracción de características primero pasaron las imágenes en el filtro de textura Haralick y Gabor, y luego utilizaron el algoritmo de selector de características, y por último, para la clasificación utilizaron redes neuronales. Utilizaron un total de 120 imágenes de semillas, donde 60 son semillas maduras y 60 inmaduras, la partición de los datos fue de 80 semillas para entrenamiento y 40 para prueba. Sus resultados se muestran en la figura x. donde obtuvieron un accuracy promedio del 0.98.




Figura 1: Semillas a clasificar, donde (a) y (b) corresponden a la clase inmadura y (c) y (d) corresponden a la clase madura.



Figura 2: Resultado método Otsu.



Figura 3: Resultado de la clasificación.

En el mismo año, Zuñiga et. al, mejora el trabajo de Avila et. al, agregando una tercera clase a clasificar, la cual es sobre-madura, en este trabajo relata, que las uvas necesitan estar en un cierto grado de madurez para obtener mejores vinos, es por ello que incluye 3 clases, no madura, madura y sobremadura. Los datos los obtuvieron mediante un escáner tradicional. Al igual que Avila, su proceso de segmentación se produjo mediante el canal c3. Al observar los resultados de la segmentación, se dieron cuenta que, existen imágenes que contienen muchos objetos que tienen áreas demasiado pequeñas o grandes para corresponder a una semilla, y además que habían partes de la semilla irreconocibles.




Imagen 4: Ejemplo de clases de semillas, donde (a) representa a la inmadura, (b) representa a las semillas maduras y (c) representa a las semillas con sobre madurez.

La solución para el tamaño de la semilla fue realizar un modelo de mezcla gaussiana con 3 categorías, semillas individuales, objetos pequeños y objetos grandes, después utilizaron un algoritmo de clustering para cada objeto y así determinar en qué categoría pertenece. Para el último problema la solución propuesta utiliza la dilatación de imagen, agrupando los objetos de la imagen no dilatada que pertenecen al mismo objeto de la imagen dilatada. Al terminar este proceso, se quedaron con 317 semillas de las 408 que inicialmente tenían antes del problema.




Figura 5: Problemas detectados, donde (a) representa a la parte de la semilla no detectado, (b) representa los objetos pequeños en las imágenes y (c) representa a las semillas de un tamaño superior.

Para obtener las características de las imágenes, se utilizaron 3 espacios de colores RGB, Cielab y Binario, donde en RGB utilizaron algoritmos como Haralick, el patrón binario local (LBP), la transformación coseno Gabor y Discreta, Fourier y Hu. A los resultados obtenidos por cada algoritmo, se utilizó el algoritmo de selector de características SFS para obtener las características más relevantes. Al final del proceso obtuvieron 159 características, donde 59 son de la clase inmadura, 62 de la clase madura, y 58 pertenecen a la clase muy madura. El proceso de clasificación fue realizado con 3 redes neuronales, una para cada clase. El set de entrenamiento consiste en 20 semillas por clase, y el set de prueba consiste en las 257 semillas restantes, donde, 33 corresponden a la clase inmadura, 190 a la clase madura y 94 a la clase sobre madura. Para la capa oculta de la red se utilizó un función de transferencia sigmoide, mientras que para la capa de salida se utiliza una función de transferencia lineal. El algoritmo de aprendizaje empleado es la regularización bayesiana, con 1000 épocas. Se fue probado entre 2 a 15 neuronas y 1000 pruebas en cada caso. El número efectivo de neuronas para las capas ocultas fue 2 para la clase inmadura y sobre madura, y 4 para la clase madura. Los resultados están descritos en la tabla 1, donde se obtuvo un accuracy de 90% en el set de entrenamiento y 86% de accuracy en el set de prueba.

Seed class	Training set			Test set		
	Qty.	Hits	Hit rate (%)	Qty.	Hits	Hit rate (%)
Immature	20	15	75	13	9	69
Mature	20	19	95	170	141	83
Over mature	20	20	100	74	71	96
Total	60	54	90	257	221	86

Tabla 1: Resultados obtenidos por Zuñiga et. al.

Rahman et. al. en el año 2014 realizó otro experimento en base a las uvas, el cual fue detectar un racimo de uva blanca en un entorno natural y clasificar si estas uvas están aptas para la cosecha. Para esto, plantearon un método de dos etapas, la primera es la segmentación de la imagen y la segunda es la clasificación del racimo de uva.




Figura 6: Representación de los racimos de uvas, donde (a) representa a las uvas maduras y (b) a las inmaduras.

Para la segmentación, detectan ciertos patrones que presentan la uva como la forma circular, el verde claro suave, el verde claro, la textura de color marrón en la superficie,

además de que en un racimo, las uvas se encuentran en las cercanías especiales entre sí. Entonces, para generar este proceso, se detectan los círculos aplicando la transformación de Hough a partir del gradiente de las imágenes de intensidad. Dado a que no utilizan color, existen varios objetos del fondo de la imagen que son marcados como uvas. Para representar la imagen, utilizan el formato HSV de la imagen, para representar los círculos que obtuvieron, se utiliza un histograma de color y un histograma de saturación. Los círculos marcados, los etiquetaron manualmente y sirvieron como entrenamiento para un clasificador clasificador Support Vector Machine (SVM). Finalmente utiliza un algoritmo de clusterización K-means, para agrupar los racimos de uvas identificados y así eliminar los posibles círculos aislados que aún estén clasificados como uvas. Para el proceso de clasificación utilizaron las características de textura en la imagen, utilizando los colores RGB, las características de la imagen se representan con un histograma de colores para cada canal del RGB y un histograma de textura, representado en 10 bins para ambos.



Figura 7: Resultado final de la Clusterización.

En la prueba de su modelo, utilizaron 31 imágenes de racimos de uva, las cuales 17 imágenes contienen uvas maduras y 14 imágenes están etiquetadas como inmaduras, el tamaño de las imágenes es de 2248x3264px 24 bit. Utilizaron un modelo generado por el clasificador SVM previamente entrenado por ellos. El resultado final fue de un 96.88% de accuracy.

En el 2016, Dolezel et. al., realizó un trabajo para detectar uvas blancas en entornos naturales, para el desarrollo de su trabajo, capturó 6 fotos de parrones que contienen varios racimos de uvas, las capturas las realizó con una cámara profesional con luz natural, el tamaño de las fotos es de 1936x1288 px, 24 bit., en formato RGB. Con estas 6 fotos, obtuvo fotos más pequeñas, de tamaño 40x40 px, y con esto formó 5 sets de entrenamiento, de 546 fotos, donde 288 pertenecen a la clase positiva y 288 a la clase negativa, y 10 sets de prueba con 400 fotos cada uno, en el cual 200 fotos están clasificadas como positiva y 200 fotos como negativa. Para el desarrollo de su experimento, cada foto la paso a escala de grises y después obtuvo el histograma orientado de gradientes (Hog), donde el tamaño de la celda es de 6x6, el tamaño de los bloques es de 2x2 con 9 bins, obteniendo un vector total de 900 características, y el vector de intensidad de píxeles, donde obtuvo un vector de 1600 características.




Figura 8: Representación de las clases, donde (a) representa a la clase positiva y el resto a la clase negativa.

Para la clasificación utilizaron una red neuronal, con una tangente hiperbólica como función de activación y utilizando el algoritmo de aprendizaje Levenberg-Marquardt. Las métricas de evaluación son el Accuracy, Precision y Recall. Para cada vector, se entrenó con una red neuronal, y sus resultados se observan en la tabla “x” y la tabla “x”, donde el vector HOG da entrega mejores resultados para todos los set de prueba.

		E-1	E-2	E-3	E-4	E-5	avg
PI	Accuracy	0.645	0.623	0.720	0.688	0.668	0.669
	Precision	0.699	0.674	0.739	0.766	0.734	0.722
	Recall	0.510	0.475	0.680	0.540	0.525	0.546
HOG	Accuracy	0.878	0.890	0.857	0.883	0.878	0.877
	Precision	0.981	0.988	0.967	0.981	0.987	0.981
	Recall	0.770	0.790	0.740	0.780	0.765	0.769

Tabla 2: Resultados de Dolezel et. al. en los primeros 5 test de prueba

		G-1	G-2	G-3	G-4	G-5	avg
PI	Accuracy	0.690	0.668	0.720	0.688	0.683	0.690
	Precision	0.817	0.802	0.737	0.786	0.783	0.785
	Recall	0.490	0.445	0.685	0.515	0.505	0.528
HOG	Accuracy	0.878	0.795	0.843	0.865	0.855	0.847
	Precision	0.987	0.976	0.986	0.980	0.967	0.979
	Recall	0.765	0.605	0.695	0.745	0.735	0.709

Tabla 3: Resultados de Dolezel et. al. en los últimos 5 test de prueba

Los autores sostienen que este trabajo es un comienzo, puesto que la idea original era detectar las uvas, pero en este trabajo, hicieron todo un preprocesamiento previo, que en el futuro desearían evitar.

Finalmente, el último trabajo a revisar es de Behrooz-Khazaei et. al. del año 2017 en donde diseñaron un método para detectar uvas blancas en entornos naturales, utilizando algoritmos genéticos y redes neuronales para la segmentación de los cluster de uvas de las hojas y del fondo. Utilizaron un total de 129 images de racimos de uvas en una viña, con iluminación natural. De aquellas imágenes tomaron 64 al azar y generaron clústeres con los distintos elementos identificados en la foto, y los clasificaron como uvas, hojas y otros. Con las imágenes ya clusterizadas, extrajeron características, las cuales son R-B, R-G; G-R;

G-B, B-R; B-G; 2G-R-B, correspondiente al espacio de color RGB, de esto generaron una matriz de 3x100. Posteriormente, generaron más características transformando los bloques RGB a H,S,V y L*,a*,b*. En total generaron una matriz de 16x19200, para los colores y 1x19200 para las etiquetas. El algoritmo genético lo utilizan para seleccionar características y calcular los parámetros de la red neuronal. En la Figura 9 se observa la arquitectura con más detalle, donde los parámetros de entrada de la red neuronal se compone de el vector de características resultante del algoritmo genético, además de las neuronas utilizadas en las capas ocultas.

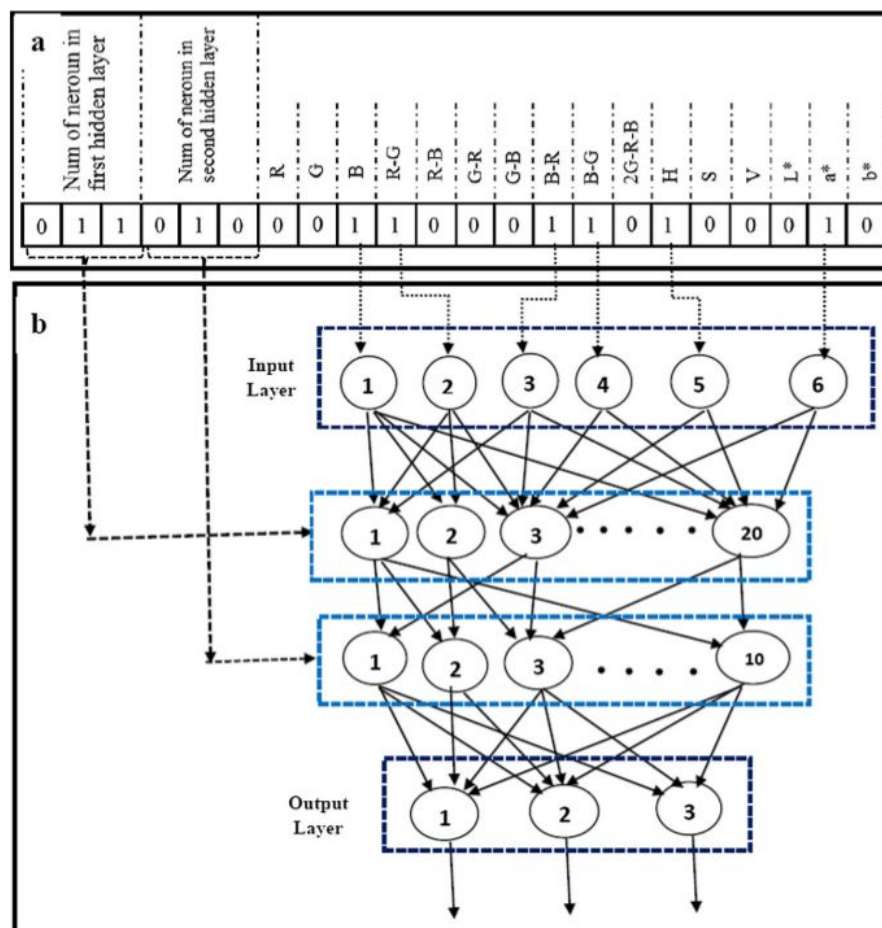


Figura 9: Representación de la arquitectura.

En la Tabla 4, se observa los resultados, donde mejoraron la clasificación con respecto a otro trabajo que resolvió esta misma problemática, donde utilizan las métricas de Especificidad, Sensitividad, Accuracy y el porcentaje de Clasificación correctas.

Classifier indicators		SE	SP	AC
ANN-GA algorithm presented in this study	Grape	99.22	99.13	99.07
	Leaf	99.83	99.76	99.50
	Others	99.15	99.80	99.61
	CCR	99.40		
GDA1 algorithm	Grape	21.77	88.14	75.78
	Foliage	88.14	21.77	40.10
	CCR	57%		

Tabla 4: Resultados de Behroozi-Khazaei et. al.

3.- Tabla de comparación.

Trabajo	Objetivo	Elemento	Captura de Imágenes	Iluminación	Resolución	Base de Datos	Cantidad de Imágenes.	Clasificador
Avila et. al. (2014)	Clasificación	Semillas	Cámara Profesional	Artificial	41x41 px	Privada	120	RNA.
Zuñiga et. al. (2014)	Clasificación	Semillas	Escanner	Artificial	41x41	Privada	408	RNA.
Rahman et. al (2014)	Detección	Uvas	Cámara Profesional	Natural	2248x3264 px	Privada	31	SVM
Dolezel et. al (2016)	Clasificación	Uvas	Cámara Profesional	Natural	1936x1288 px	Pública	6	RNA.
Behrooz-Khazaei et. al. (2017)	Detección	Uvas	Cámara Profesional	Natural	No específica.	Pública	129	RNA.

Tabla 5: Comparación entre los 5 papers.

4.- Referencias.

- Avila, F., Mora, M., & Fredes, C. (2014). A method to estimate Grape Phenolic Maturity based on seed images. Computers and electronics in agriculture, 101, 76-83.
- Behrooz-Khazaei, N., & Maleki, M. R. (2017). A robust algorithm based on color features for grape cluster segmentation. Computers and Electronics in Agriculture, 142, 41-49.
- Dolezel, P., Skrabanek, P., & Gago, L. (2016, July). Detection of grapes in natural environment using feedforward neural network as a classifier. In SAI Computing Conference (SAI), 2016 (pp. 1330-1334). IEEE.
- Rahman, A., & Hellicar, A. (2014, December). Identification of mature grape bunches using image processing and computational intelligence methods. In Computational Intelligence for Multimedia, Signal and Vision Processing (CIMSIVP), 2014 IEEE Symposium on (pp. 1-6). IEEE.
- Zuñiga, A., Mora, M., Oyarce, M., & Fredes, C. (2014). Grape maturity estimation based on seed images and neural networks. Engineering Applications of Artificial Intelligence, 35, 95-104.